DATA MANAGEMENT & KNOWLEDGE GRAPHS

# Organiser la donnée

Des sources dispersées à une information **fiable, gouvernée et réutilisable**.

SOURCES · CURATION · GOUVERNANCE · KNOWLEDGE · MISE À DISPOSITION

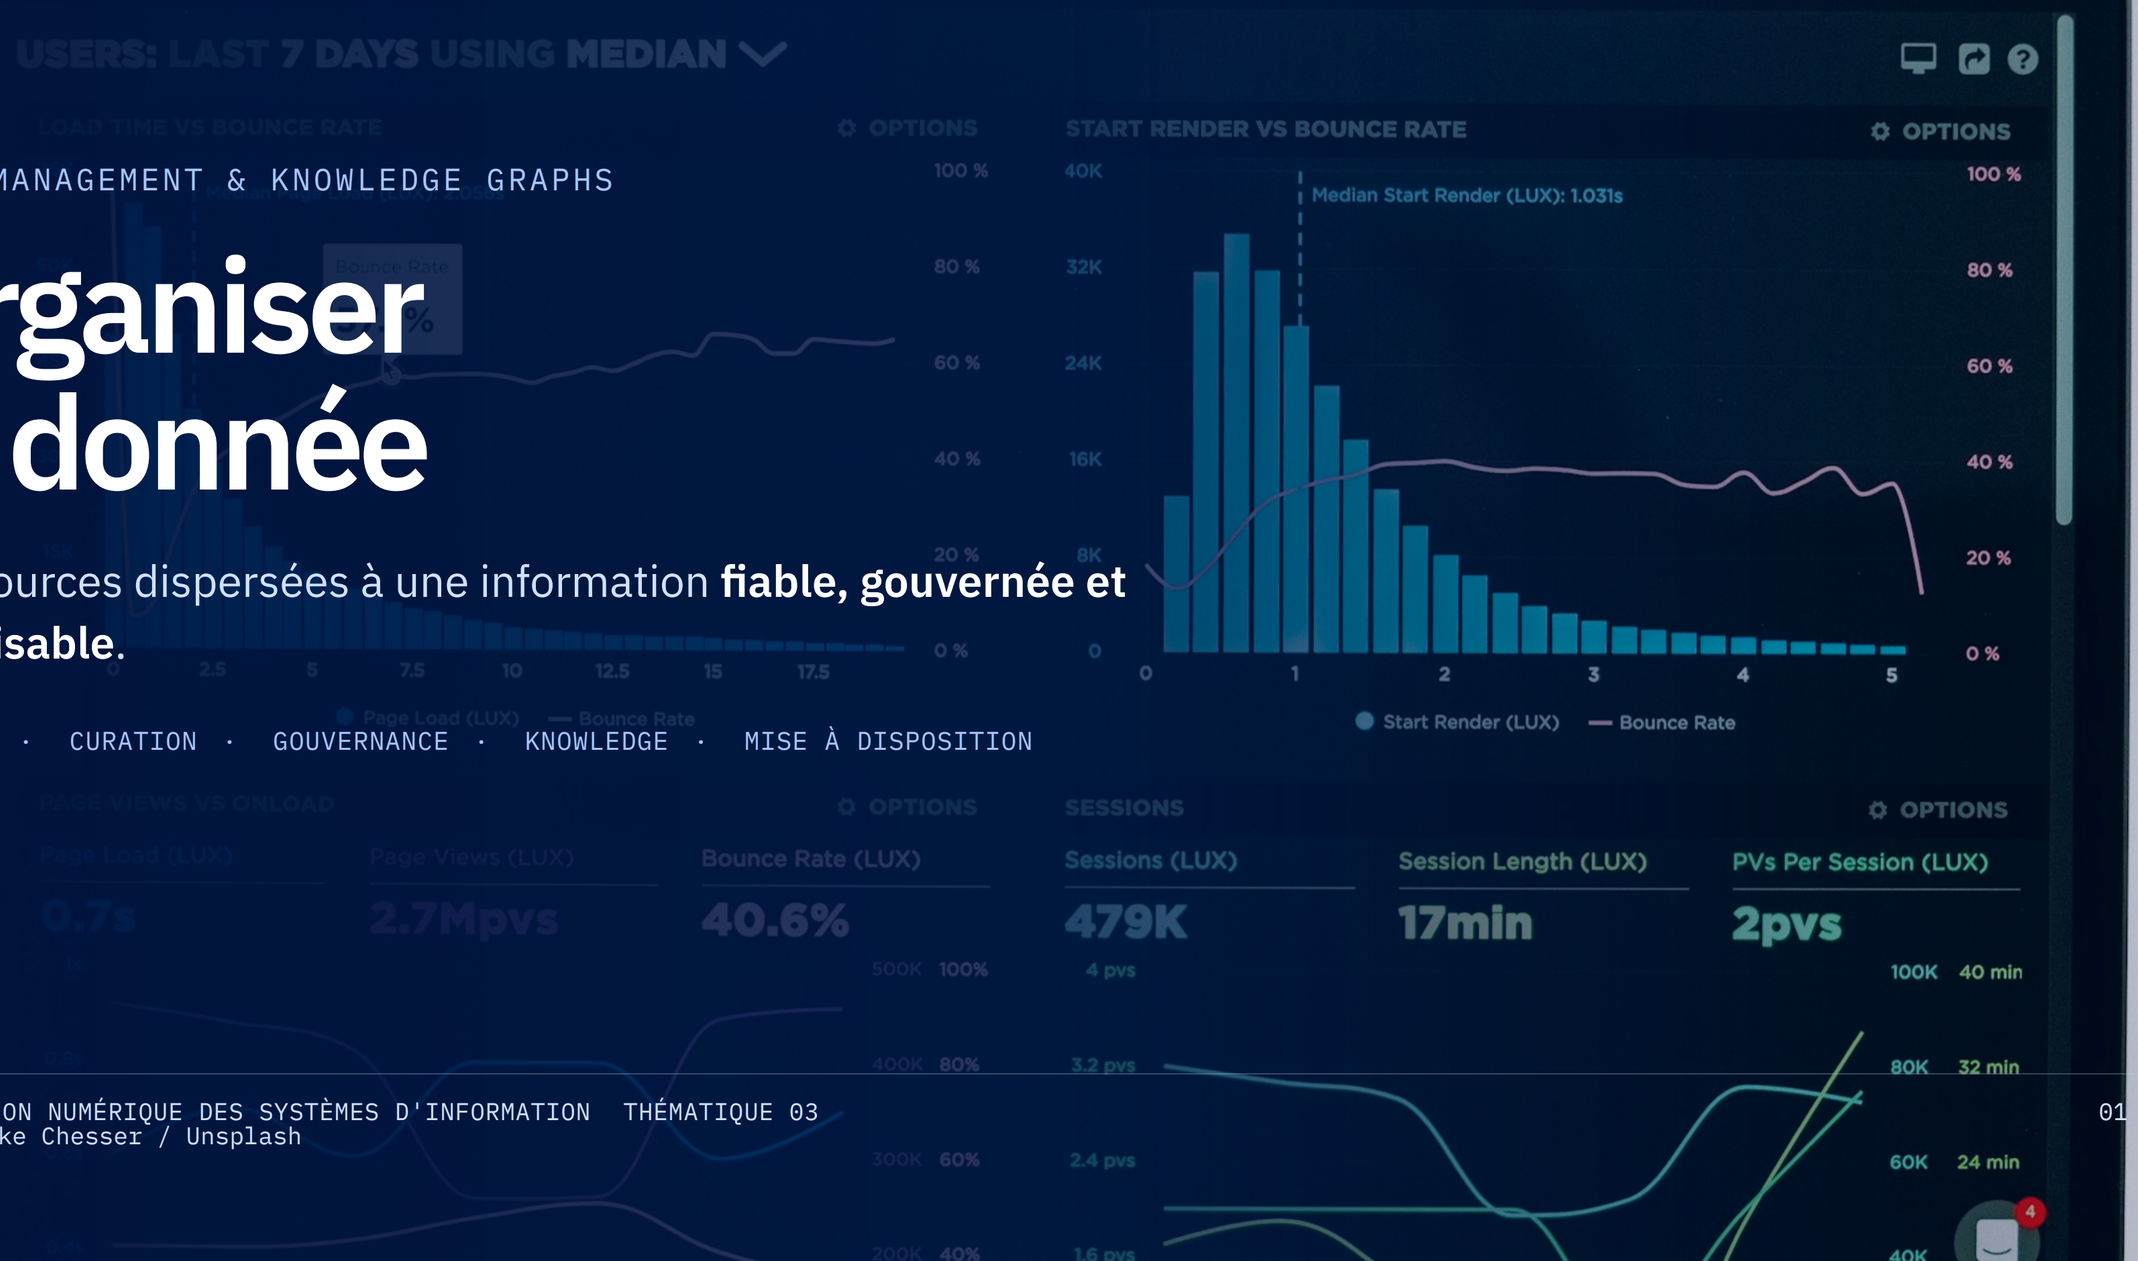
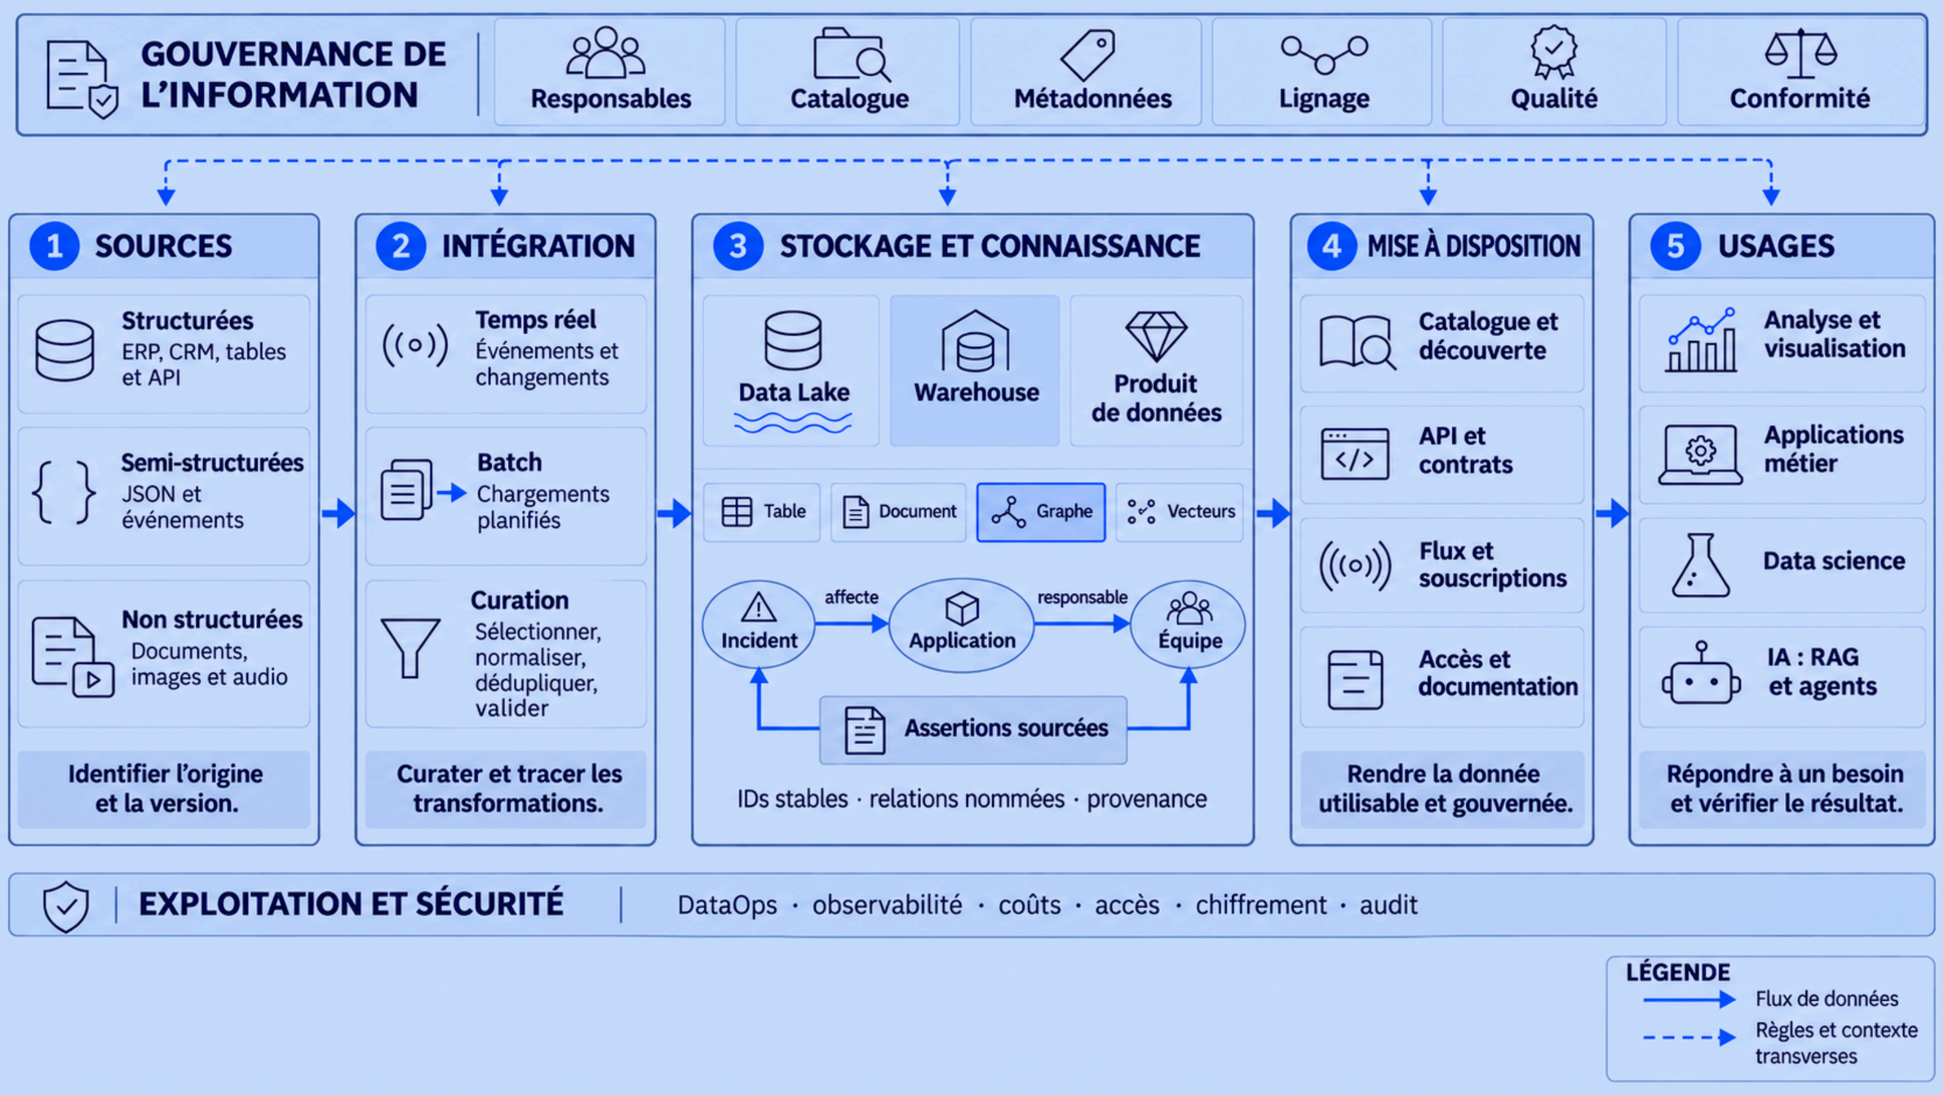




Photo Luke Chesser / Unsplash

# C'est normal de ne pas tout comprendre maintenant.

À la fin du cours, vous saurez raconter le trajet de la source à la mise à disposition et aux usages.



LA PROMESSE

# Lire une architecture data, puis rendre la donnée utilisable.

01



## Sources

Identifier l'origine, la version et l'autorité.

02



## Curation

Nettoyer, normaliser et conserver la provenance.

03



## Stockage

Distinguer entrepôt, lac et lakehouse.

04



## Gouvernance

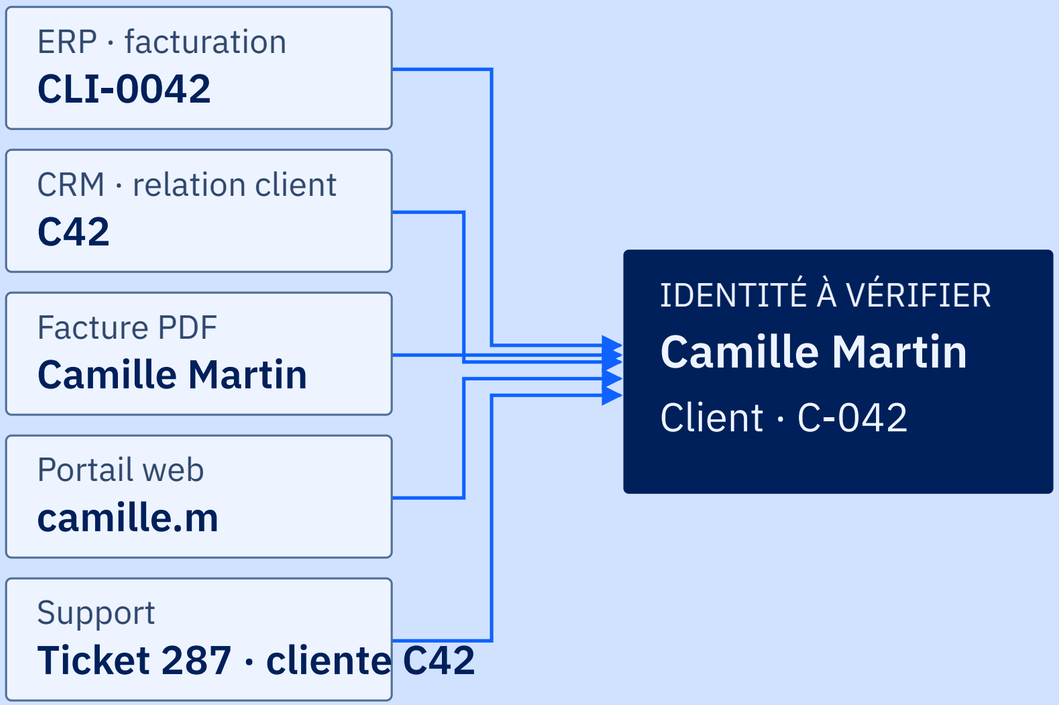
Attribuer les responsabilités, protéger et maîtriser les usages IA.

05



## Mise à disposition

Exposer la donnée avec un contrat et des accès maîtrisés.




Rapprocher avec des preuves ; un nom commun ne suffit pas.

CONTEXTE D'ORGANISATION

# Beaucoup de données. Pas encore une vérité partagée.

Les systèmes décrivent parfois le même objet avec des identifiants, des formats et des propriétaires différents.

Notre travail commence par rendre ces différences **explicites et traçables**.

# Un SI est un archipel de sources.

### Relation client

CRM · centre de contact · e-commerce

Clients · interactions · préférences

### Opérations

ERP · stocks · transport · production

Commandes · livraisons · mesures IoT

### Fonctions support

Finance · RH · achats · juridique

Factures · paie · contrats

### Travail quotidien

GED · messagerie · wiki · fichiers

PDF · présentations · feuilles Excel

### Produits numériques

Applications · API · logs · analytics

Clics · événements · incidents

### Écosystème externe

Partenaires · open data · fournisseurs

Météo · tarifs · référentiels

Un indicateur peut croiser plusieurs applications : identifiants, définitions, rythme et droits doivent s’accorder.

# La structure du contenu guide le traitement.

01

## Structuré

Un schéma explicite organise les valeurs.

Tables SQL · CSV · Parquet

```
C42 | FR | 2026-11-12
```

02

## Semi-structuré

Des clés ou balises portent une organisation souple.

JSON · XML · logs

```
{"client_id": "C42"}
```

03

## Non structuré

Le sens est dans le texte, le son, l’image ou la mise en page.

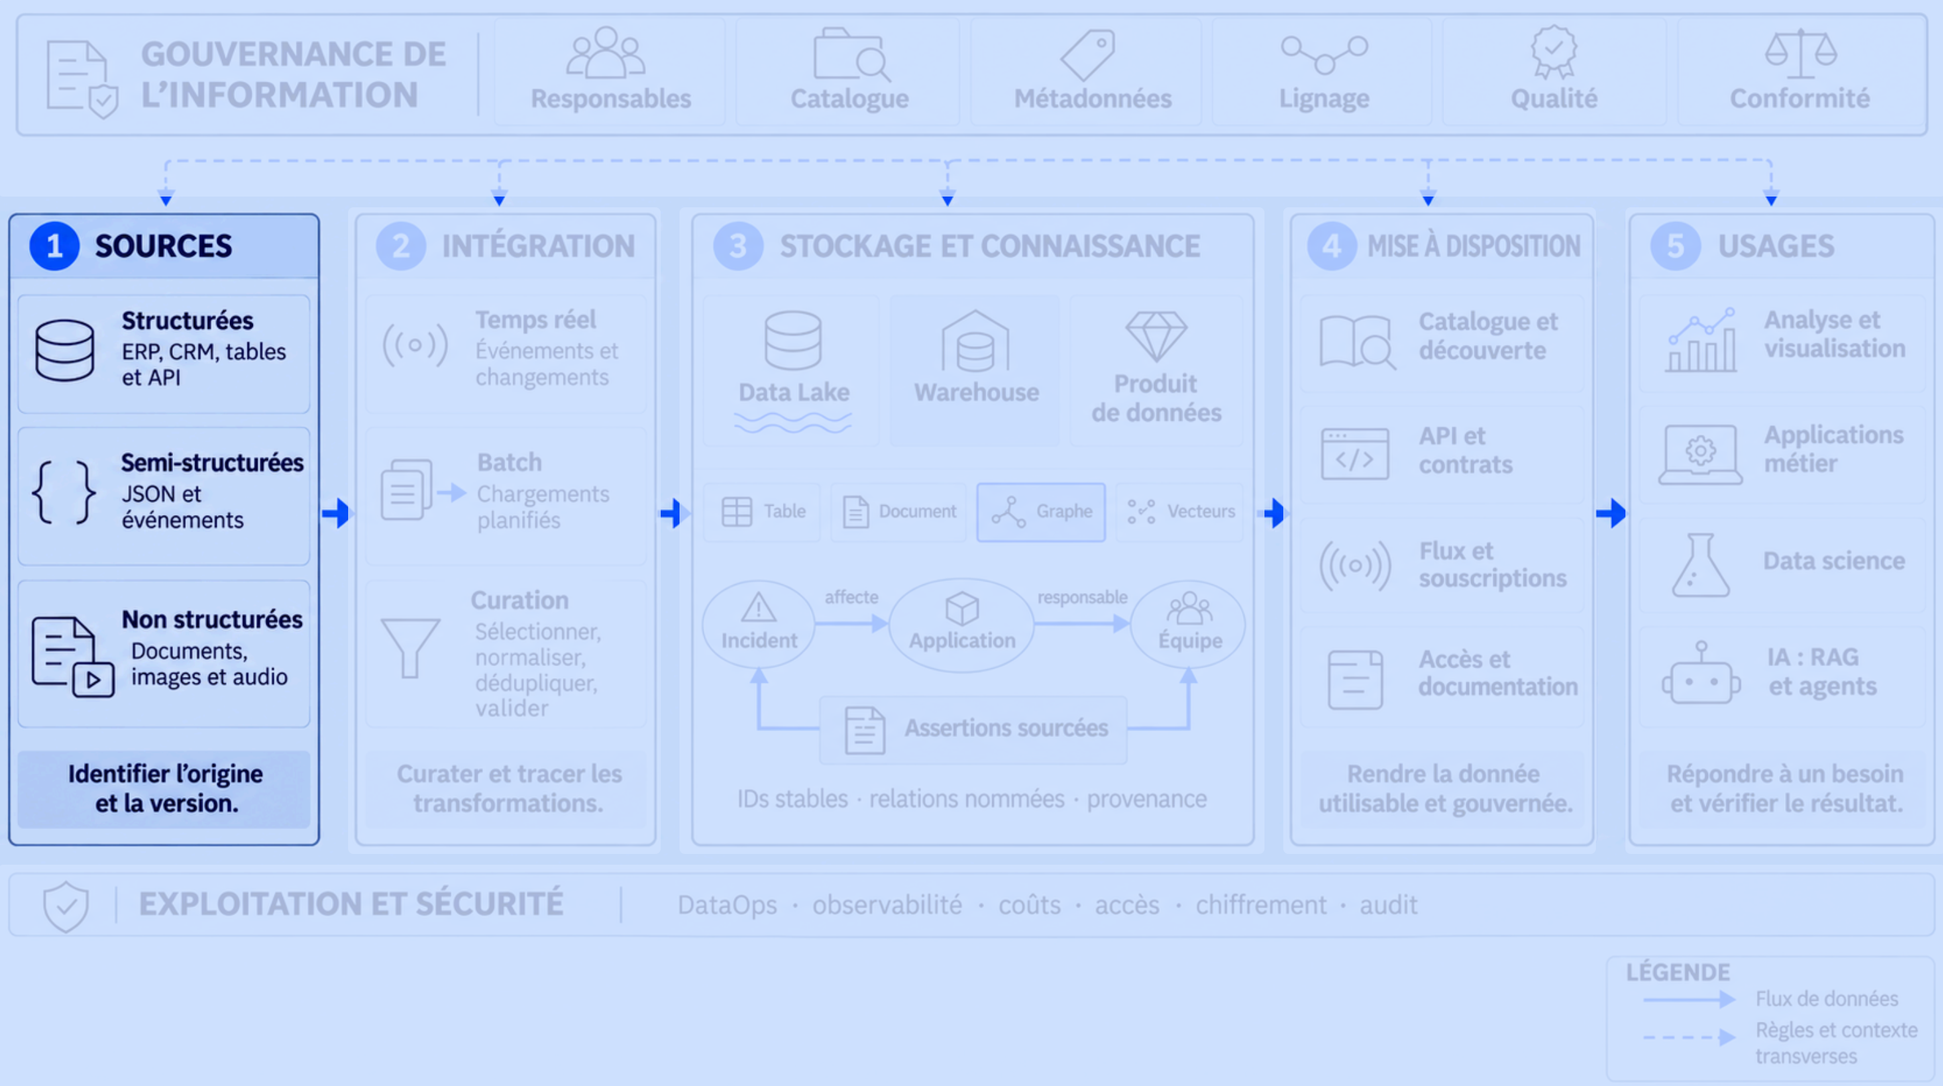
PDF · PPT · e-mail · vidéo · audio

Extraction, OCR ou transcription

Un PDF peut contenir une table ; une base NoSQL peut stocker des documents structurés. SQL, NoSQL et vecteurs désignent des modèles ou techniques de stockage/recherche, pas des formats de fichier.

# Toute donnée commence quelque part.

Avant de transformer : identifier l'autorité, la version et les conditions d'usage.



TRANSFORMER SANS PERDRE L'ORIGINE

# Curater, c'est construire la confiance.

ENTRÉE

## Données brutes

Doublons, alias, champs absents, formats hétérogènes.

→

- sélectionner
- normaliser
- dédupliquer
- enrichir
- valider

→

SORTIE

## Donnée qualifiée

Identité, qualité, version et provenance explicites.

# La qualité se mesure pour un usage.

| DIMENSION | CONTRÔLE CONCRET | ACTION SI ÉCHEC |
|---|---|---|
| **Complétude** | Le pays nécessaire à la facturation est renseigné. | Compléter ou bloquer la publication. |
| **Validité** | Le code pays appartient au référentiel ISO choisi. | Corriger avec une règle traçable. |
| **Unicité** | La clé de commande ne se répète pas. | Dédupliquer sans perdre l’historique. |
| **Cohérence** | Le total et les lignes de facture concordent. | Rapprocher les systèmes. |
| **Exactitude** | L’adresse correspond à une source vérifiée. | Faire confirmer par le responsable. |
| **Fraîcheur** | La mise à jour respecte le délai du contrat. | Alerter et afficher le retard. |

Profiler → définir les règles → tester à chaque chargement → isoler les rejets → surveiller → corriger à la source. Les seuils dépendent du besoin métier.

# La qualité : observer avant de corriger.




### 1 · Repérer

Quel défaut de donnée ou de contexte pose problème ?

### 2 · Relier

Quelle décision devient moins fiable ?

### 3 · Agir

Quel contrôle, quelle alerte et quel responsable proposer ?

Ouvrir directement sur YouTube ↗

# Raw → Curated → Gold : des engagements croissants.

01

## Raw

Souvent Bronze

Conserver une copie proche de la source, horodatée et traçable.

CRM v3

```
pays = "fr"
```

→

02

## Curated

Souvent Silver

Typer, nettoyer, rapprocher, dédupliquer et valider les données.

Référence client

```
pays = "FR"
```

→

03

## Gold

Prêt pour un usage

Publier des données métier contrôlées : tables, indicateurs ou produits.

Clients actifs par pays

Définition + contrat de fraîcheur

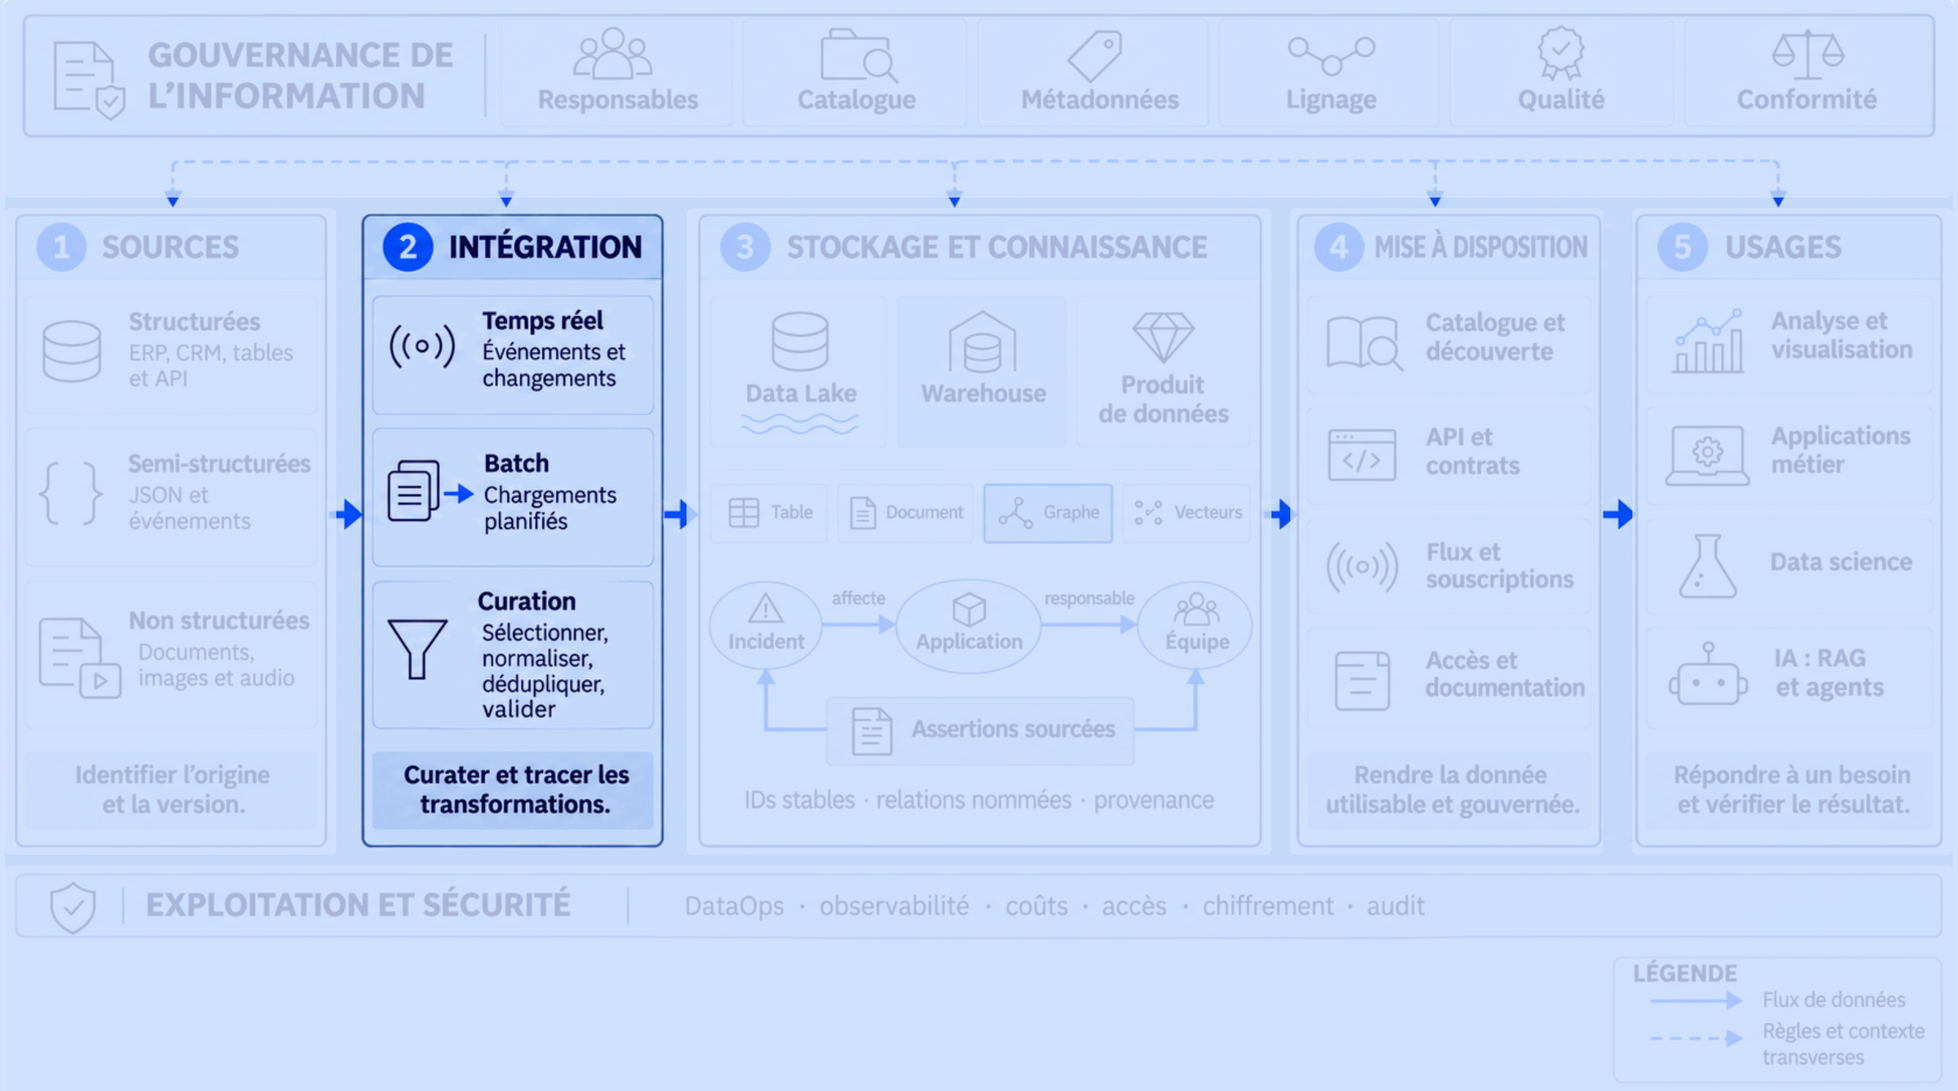
Catalogue · métadonnées · lineage · qualité · accès et conservation dans chaque zone

Une organisation de la maturité, pas une obligation de copier trois fois. Les noms et frontières varient ; « Gold » ne signifie ni « public » ni « sans erreur ».

Source : Databricks · architecture médaillon

# La curation traverse les zones de données.

De Raw à Curated puis Gold : contrôler et documenter les transformations, y compris après le stockage.



PROVENANCE · TRANSFORMATIONS · RÉSULTAT

# Le data lineage retrace le parcours d’une donnée.

Le data lineage (lignage) décrit l’origine d’une donnée, les transformations qu’elle a subies et les résultats qui en dépendent. Il permet de remonter une erreur et d’anticiper l’impact d’un changement.




**Métadonnées :** propriétaire, version, qualité, statut.
**Lineage :** les liens source → transformations → résultat.

# Data Warehouse : organiser l’analyse.

Un entrepôt rassemble des données préparées pour des analyses cohérentes et répétées.




## Préparer à l’écriture

Intégration, nettoyage, modèle métier et règles de calcul précèdent la publication.

## Exploiter

SQL et BI interrogent des tables organisées ; les indicateurs partagent les mêmes définitions.

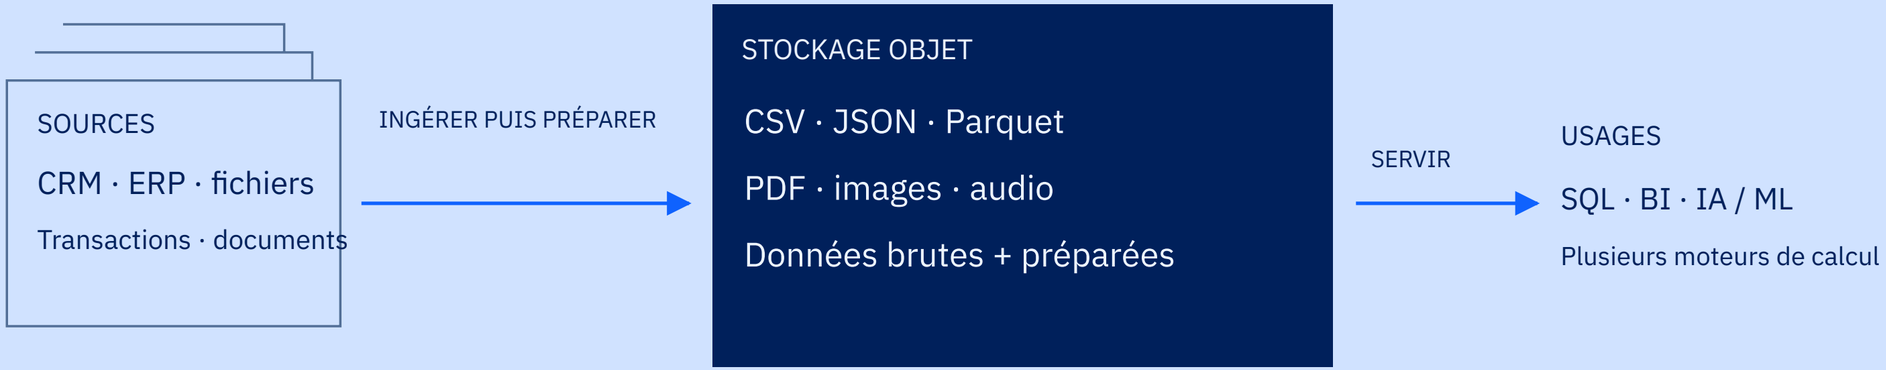
## Compromis

Le modèle facilite le reporting ; son évolution et les transformations demandent du travail.

Référence : Armbrust et al. · CIDR 2021 · vues pédagogiques simplifiées

# Data Lake : conserver des matériaux variés.

Un lac stocke des données de formats variés, puis permet de les préparer selon les usages.




### Conserver

Fichiers proches de la source, données préparées et contenus multimédias peuvent coexister.

### Exploiter

Des moteurs distincts lisent et transforment les données : exploration, traitement distribué, IA.

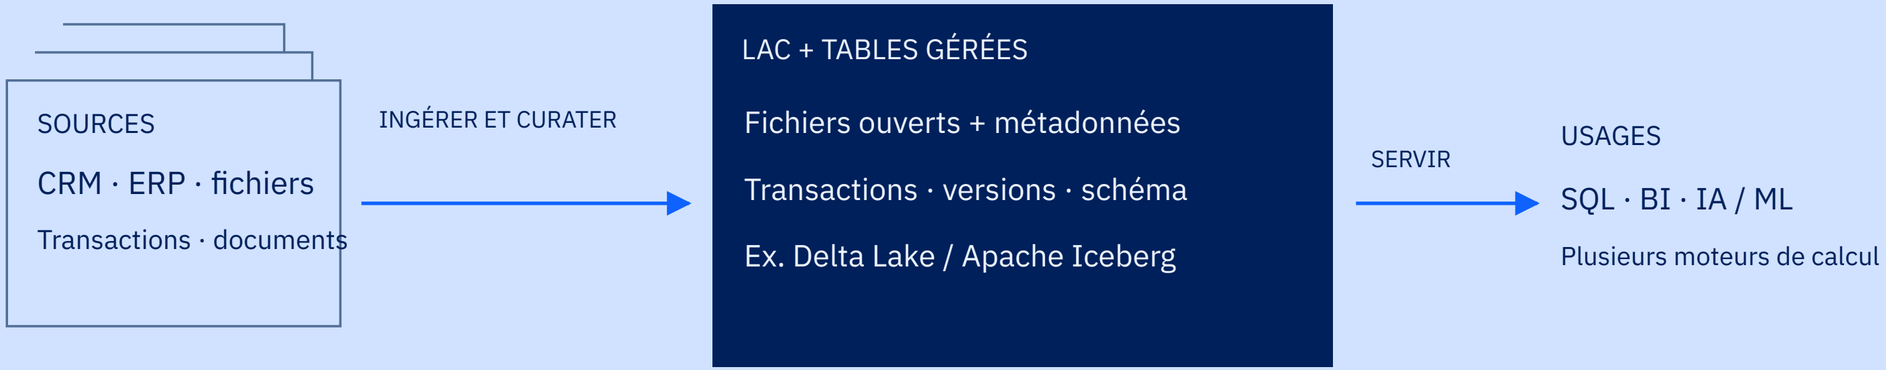
### Compromis

Sans catalogue, qualité et droits, le lac devient difficile à découvrir et à exploiter.

Référence : Armbrust et al. · CIDR 2021 · vues pédagogiques simplifiées

# Data Lakehouse : gérer des tables sur le lac.

Une couche de gestion apporte aux fichiers du lac des garanties utiles à l'analyse.




## Gérer les tables

Transactions, suivi des versions et contrôle du schéma s'appuient sur un format de table.

## Partager le socle

BI et IA peuvent exploiter des tables gouvernées sur un même stockage objet.

## Compromis

Le choix des formats et des moteurs compte ; gouvernance et qualité restent à construire.

Référence : Armbrust et al. · CIDR 2021 · vues pédagogiques simplifiées

# La représentation dépend de la question.

| REPRÉSENTATION | CE QUE L'ON CHERCHE | EXEMPLE |
|---|---|---|
| **Tables SQL** | Filtrer, joindre, agréger sous contraintes. | Chiffre d'affaires par pays |
| **NoSQL : document / clé-valeur** | Lire un objet flexible ou accéder par clé. | Profil client JSON / session |
| **Fichiers & documents bruts** | Conserver et relire le contenu original. | PDF, vidéo, CSV dans un stockage objet |
| **Graphe** | Suivre des relations explicites et leurs preuves. | Client → commande → livraison |
| **Vecteurs** | Retrouver une proximité selon un modèle. | Passages proches du sens d'une question |

> Un même contenu peut avoir plusieurs projections. Un vecteur ne prouve pas un fait ; le graphe et l'index doivent garder un lien vers leurs sources.

# Un fichier .md peut porter une connaissance sourcée.

knowledge/claims-2025.md · exemple fictif

```
---
type: Metric
title: Réclamations reçues en 2025
sources:
  - id: annex-c
    resource: /sources/annex-c.md
status: stable
stale_after: 2027-10-06T00:00:00Z
---
Globex a reçu 210 000 réclamations en 2025,
dont 38 % par formulaire web.
Voir [le système de réclamations](/client/systems.md).
```

### Frontmatter YAML

Type, sources, statut et date de réexamen deviennent lisibles par un programme.

### Corps Markdown

Une explication relie le chiffre à son contexte et aux autres concepts.

### Open Knowledge Format

Une spécification ouverte de fichiers Markdown avec métadonnées et liens ; ici, un exemple simplifié de la v0.2.

> Écrire une source ne valide pas le chiffre. Il faut vérifier le calcul et maintenir le document.

Source : spécification OKF v0.2

# Data → information → connaissance.

DATA · OBSERVATION

## 48 h

Une valeur isolée ; ni objet, ni date, ni unité métier.

→

INFORMATION · CONTEXTE

## Délai C42

La commande du client C42 a été livrée en 48 h.

→

KNOWLEDGE · SENS ÉTAYÉ

## Engagement tenu

Le contrat prévoit 72 h ; les événements de livraison prouvent le respect du délai.

La connaissance relie observations, définitions, règles et preuves pour répondre à une question. Elle peut vivre dans des documents, des règles ou un graphe ; elle doit être révisée quand le contexte change.

# Les domaines organisent le sens et la responsabilité.

### Clients

Identité · consentements · contacts

### Ventes

Commandes · prix · canaux

### Logistique

Stocks · livraison · transport

### Finance

Factures · paiements · clôture

### Ressources humaines

Collaborateurs · compétences · paie

### Risques & conformité

Contrôles · incidents · obligations

Parcours de commerce fictif : Clients → Ventes → Logistique → Finance. Les mêmes mots peuvent changer de sens : « client actif » pour le marketing n’est pas nécessairement « compte facturé » pour la finance.

AU-DELÀ DE LA BASE

# Une base de données n'est pas encore un produit.




POUR QUI ?

## Des utilisateurs

Des besoins et des questions identifiés.

PAR QUI ?

## Un responsable

Quelqu'un répond de la qualité et de l'évolution.

COMMENT ?

## Un contrat

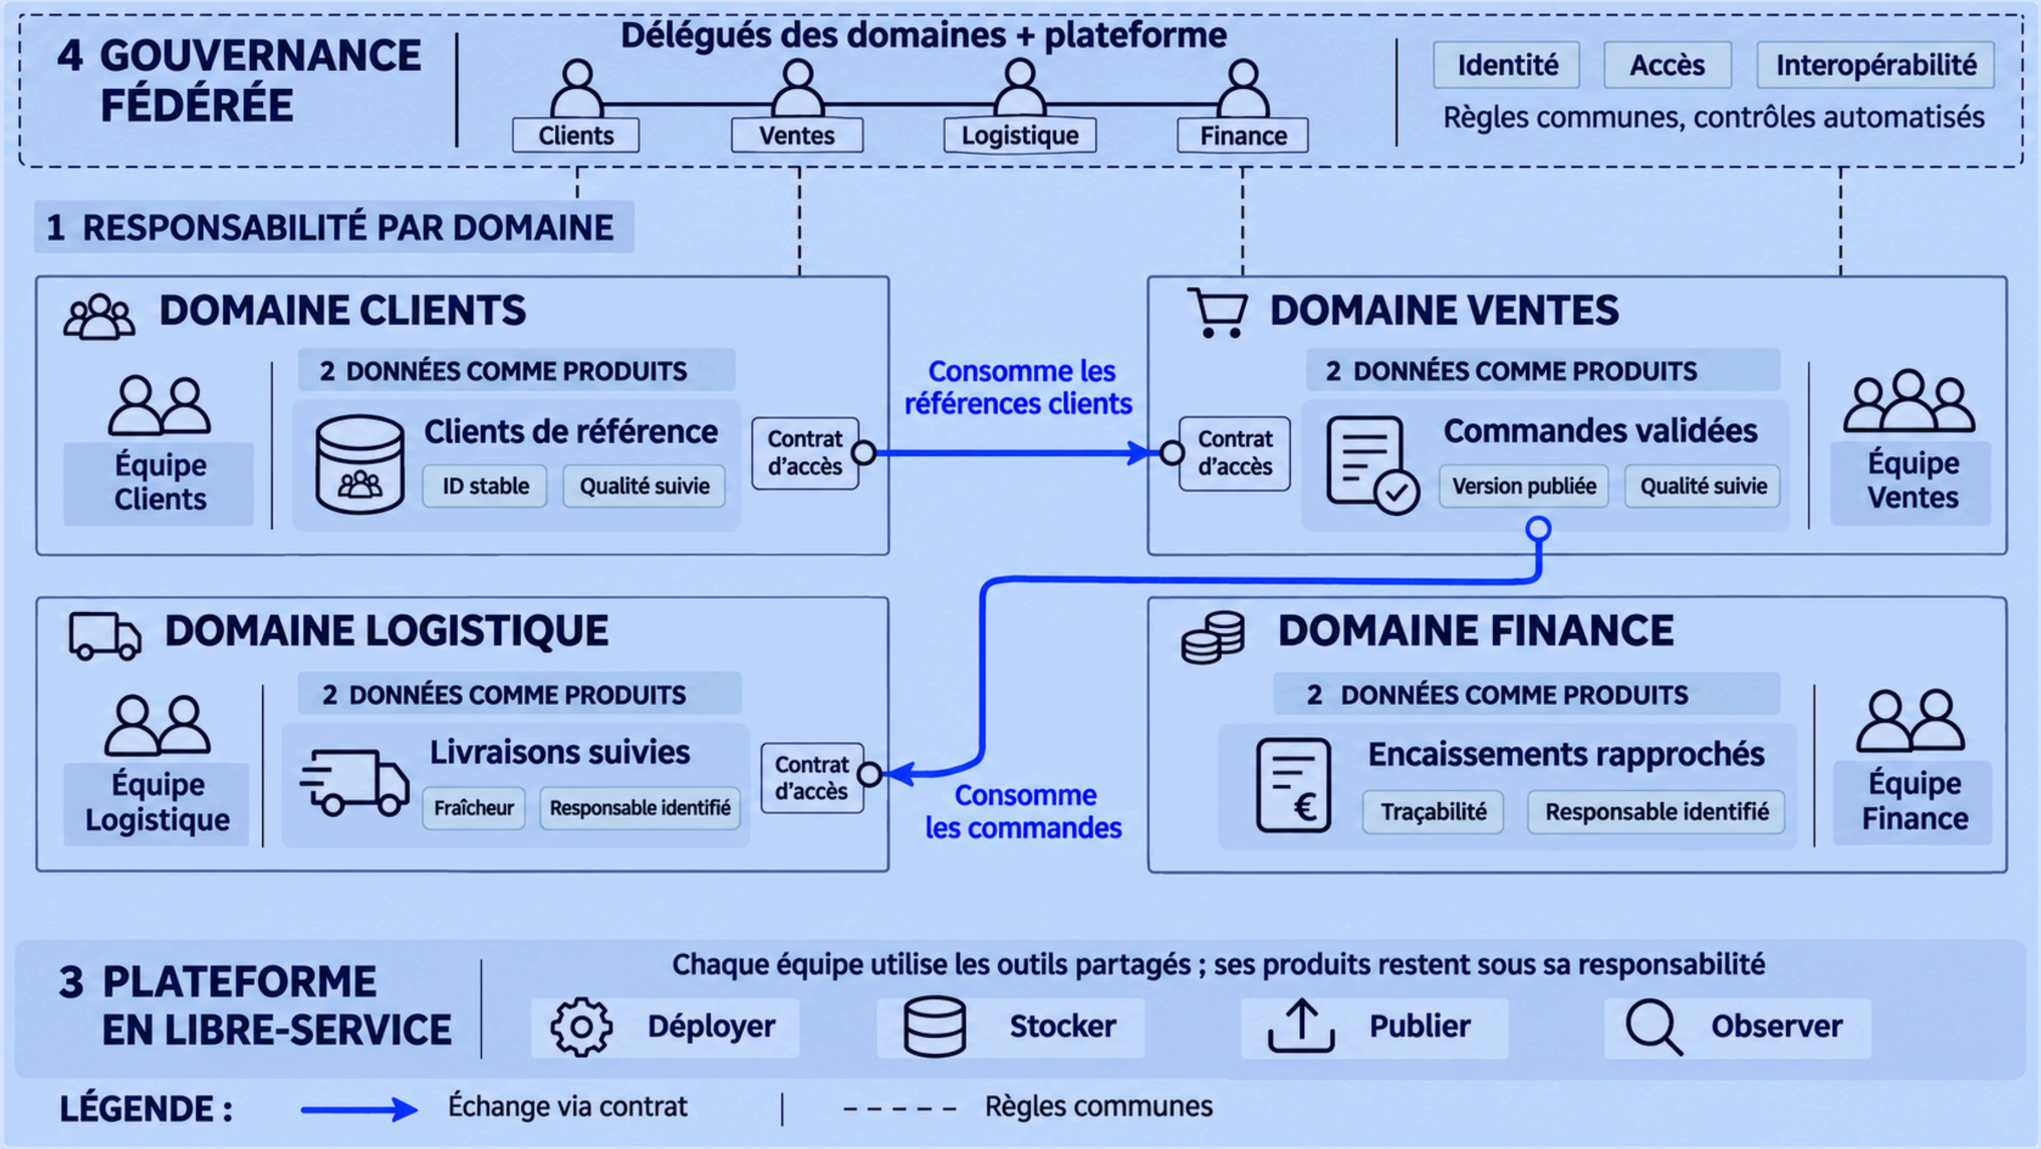
Schéma, accès, documentation et règles d'usage.

AVEC QUELLE CONFIANCE ?

## Une qualité visible

Fraîcheur, complétude, provenance et limites.

# Distribuer la responsabilité, garder des règles communes.



# Gouverner l’information, c’est décider qui en répond.



Annie Spratt / Unsplash · scène de travail

**Définir**

Que signifient les données et quelle source fait autorité ?

**Attribuer**

Qui décide du niveau de qualité et arbitre les usages ?

**Protéger**

Qui accède à quoi, pour quelle finalité et combien de temps ?

**Démontrer**

Catalogue, règles, décisions, lineage et journaux permettent de rendre des comptes.

> Exemple : un assistant de relation client peut lire les commandes autorisées ; le dossier RH conserve un périmètre distinct.

# Dans chaque domaine : décider, tenir et construire.

| RÔLE | RESPONSABILITÉ PRINCIPALE | SUR LE PRODUIT « RÉFÉRENCE CLIENT » |
|---|---|---|
| **Data Owner / Product Owner** | Le métier arbitre le sens, les usages, la qualité attendue et les habilitations selon la politique. | Valide la définition du client actif et les usages autorisés. |
| **Data Steward** | Tient les définitions, le catalogue et les règles de qualité ; suit et escalade les anomalies. | Documente les identifiants, les doublons et les limites. |
| **Data Engineers** | Construisent et exploitent ingestion, curation, tests et interfaces. | Implémentent les contrôles, le filtrage et la traçabilité. |

Circuit type : besoin métier → décision du responsable → mise en œuvre technique → suivi par le steward. Les intitulés et cumuls de rôles varient selon l’organisation.

# Des fonctions communes soutiennent les domaines.

| FONCTION | CE QU'ELLE APPORTE | AVEC QUI ? |
|---|---|---|
| **Data Governance Lead / CDO** | Cadre commun : définitions, priorités, responsabilités, arbitrages interdomaines. | Responsables métier et stewards |
| **Data Platform Team** | Capacités partagées : catalogue, stockage, pipelines, contrôle des accès et observabilité. | Équipes data des domaines |
| **RSSI / sécurité** | Politique de sécurité, risques, exigences de protection et réponse aux incidents. | Plateforme et responsables métier |
| **DPO + juridique** | Le DPO conseille et contrôle le respect du RGPD ; le juridique éclaire les obligations et contrats. | Responsable du traitement et équipes projet |

> Le steward ne remplace pas le DPO et ne lui est pas nécessairement rattaché. Le responsable du traitement conserve sa responsabilité ; le DPO exerce sa mission avec indépendance.

Source : CNIL · missions et indépendance du DPO

# Être authentifié ne donne pas tous les droits.

### Identité

IAM · SSO · MFA
Qui demande ?

→

### Politique d’accès

Identité + action + ressource
Autoriser cette demande ?

→

### Donnée autorisée

Table · ligne · colonne · document
Filtrer et tracer

| MODÈLE | RÈGLE ILLUSTRATIVE |
|---|---|
| **RBAC · par rôle** | Un rôle « agent de facturation » peut consulter les factures de son périmètre. |
| **ABAC · par attributs** | Autoriser si domaine, région du dossier, finalité et contexte satisfont la politique. |

Moindre privilège · refus par défaut · accès limités dans le temps · retrait au départ ou au changement de poste · revue des droits et audit.
Le chiffrement complète ces contrôles.

CNIL · habilitations · NIST · ABAC

# Masquer, pseudonymiser, anonymiser : trois effets.

01

## Masquer / chiffrer

Réduire l’exposition : cacher un champ ou le rendre illisible sans clé.

`c***@exemple.fr`

La donnée reste personnelle si l’on peut identifier la personne.

02

## Pseudonymiser

Remplacer les identifiants directs ; protéger et séparer la correspondance.

`Camille → token-7F2`

La réidentification reste possible : le RGPD continue à s’appliquer.

03

## Anonymiser

Rendre l’identification impossible en pratique, compte tenu des moyens raisonnables.

Agrégation, généralisation ou bruit. Tester individualisation, corrélation et inférence.

Retirer le nom ne suffit pas. Une région + une année de naissance + un identifiant peuvent encore permettre un rapprochement. Le compromis entre utilité et risque doit être évalué dans le temps.

Source : CNIL · anonymisation et réidentification

# Les obligations dépendent des données et de l’usage.

| CADRE | PÉRIMÈTRE | CONSÉQUENCE POUR LA PLATEFORME |
|---|---|---|
| **RGPD + loi Informatique et Libertés** | Traitements de données personnelles. | Finalité et base légale ; minimisation, conservation, droits et sécurité. |
| **NIS2** | Entités concernées selon secteur, taille et cadre national. | Gestion des risques cyber, continuité et gestion des incidents. |
| **Règlement européen sur l’IA** | Obligations selon le système, son risque et le rôle de l’organisme. | Pour les systèmes à haut risque concernés : gouvernance des données d’entraînement, de validation et de test. |
| **Contrats & cadres sectoriels** | Secret, licences, santé, finance ou paiement selon le cas. | Limiter réutilisations, transferts et destinataires ; conserver les preuves. |

Avant d’exposer : classifier → identifier les textes et contrats applicables → traduire en règles d’accès, de conservation et de traçabilité. PCI DSS est un standard de sécurité des cartes, pas une loi générale sur toutes les données.

CNIL · RGPD · ANSSI · NIS2 · Commission européenne · IA, art. 10

# L’IA multiplie les copies et les chemins d’accès.

**Documents**

Sources + droits
+ classification

→

**Index / graphe**

Fragments + vecteurs
+ provenance + droits

→

**Contexte du modèle**

Uniquement les éléments
autorisés à l’utilisateur

→

**Réponse**

Sources visibles
+ contrôle des sorties

### Droits de bout en bout

Le filtrage intervient avant l’envoi au modèle. Une consigne dans le prompt ne remplace pas une autorisation.

### Cycle de vie étendu

Révocation, correction et suppression doivent couvrir index, caches et journaux selon leurs règles de conservation.

### Qualité & risques nouveaux

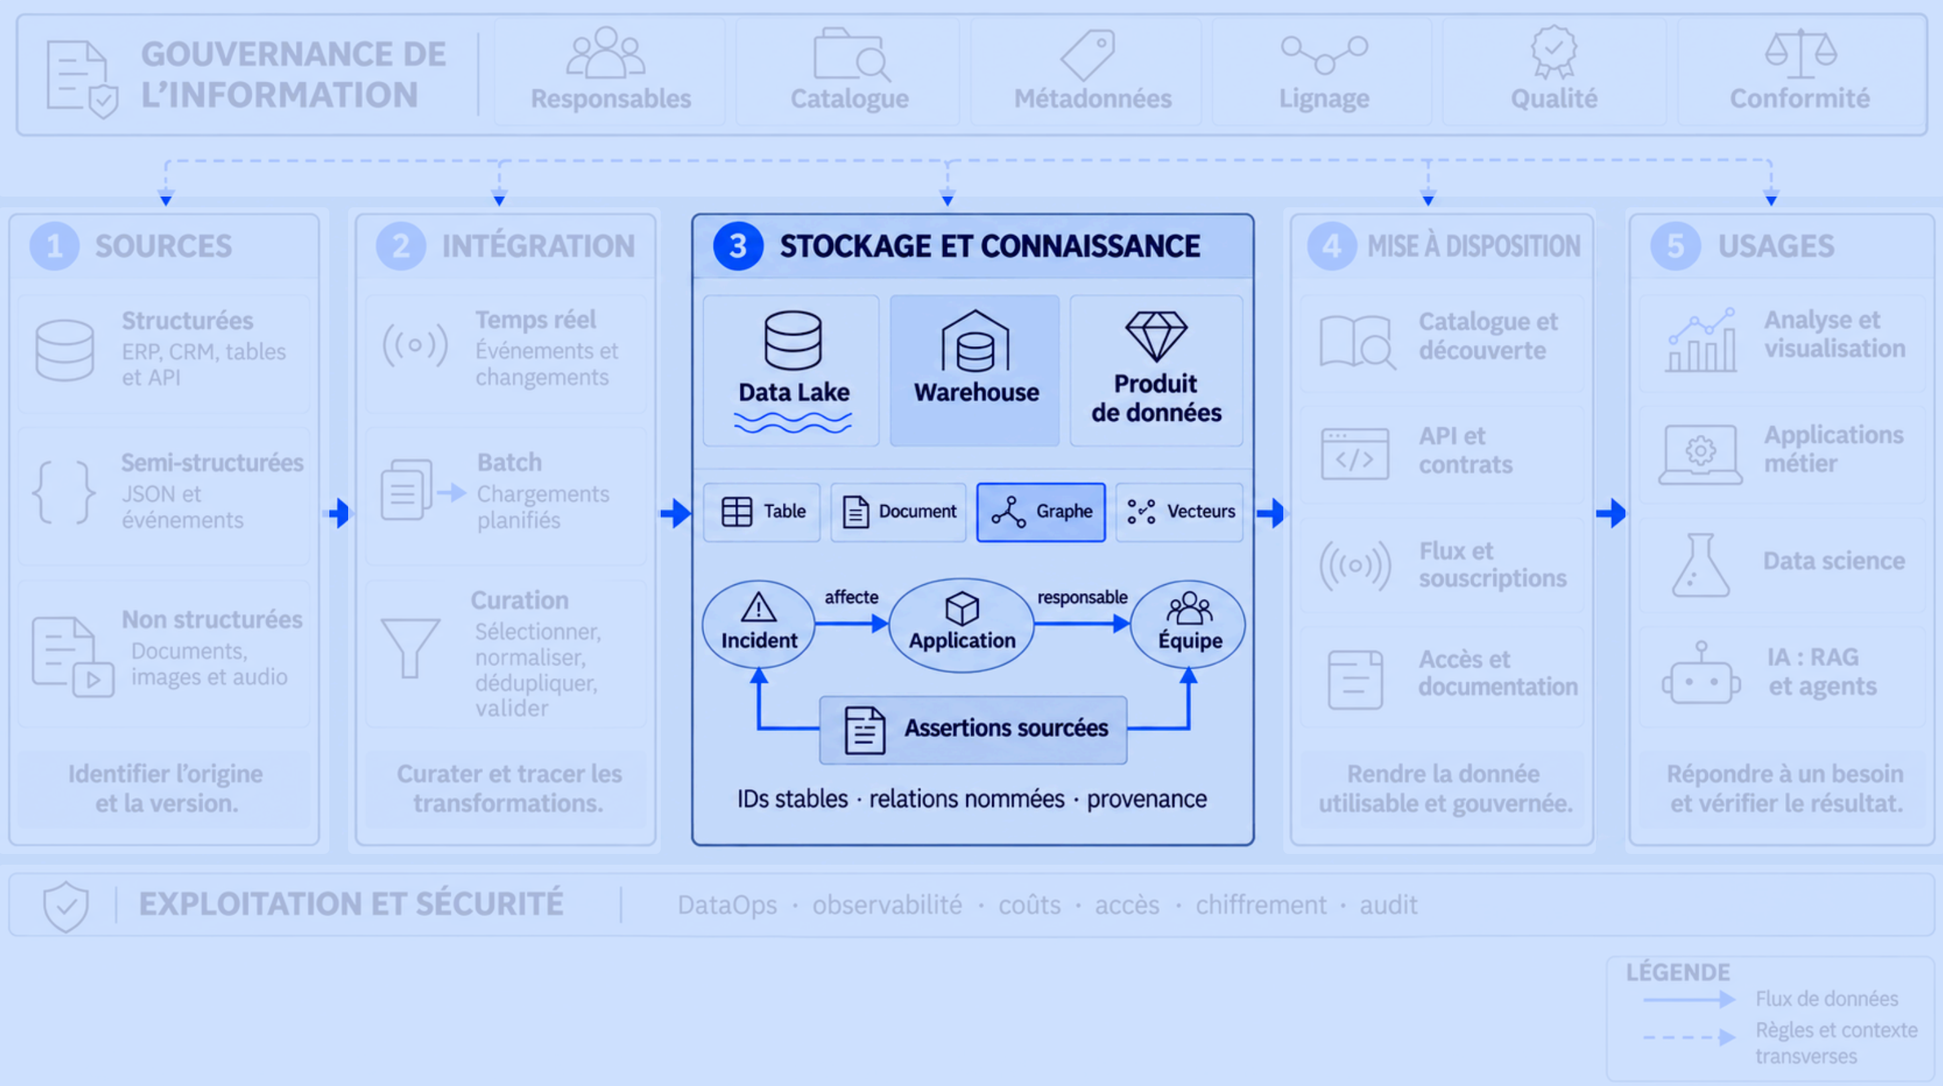
Corpus à jour, tests de réponses et de fuites, résistance aux injections et périmètre des outils d’agent.

> Distinguer entraînement, ajustement et RAG : les données transmises et les usages diffèrent. Encadrer la réutilisation par le fournisseur, les transferts et les accès des comptes techniques.

CNIL · IA générative · CNIL · sécurité IA

# La connaissance relie données, règles et preuves.

Le domaine donne le sens ; documents, graphes et index en proposent des vues adaptées aux usages, reliées aux sources.



# Mettre à disposition : API, exports ou flux.

PRODUIT DE DONNÉES

## Une donnée qualifiée

Schéma, qualité, provenance et responsable connus.



INTERROGER À LA DEMANDE

### API · SQL · requête graphe

Un service contrôle l’accès et retourne une réponse dans un schéma défini.

TRANSMETTRE UN INSTANTANÉ

### Export · fichier · table partagée

Un jeu versionné pour analyser ou échanger ; fraîcheur et périmètre explicites.

SUIVRE LES CHANGEMENTS

### Flux · événements · souscription

Des mises à jour livrées aux consommateurs autorisés, avec règles de reprise.

# Le même produit s’expose sous plusieurs formats.

| MODE D’ACCÈS | FORMAT POSSIBLE | CONTRAT À EXPLICITER |
|---|---|---|
| **Fichier / instantané** | CSV · Parquet · JSON | Schéma, version, partition, date de référence et périmètre. |
| **API / requête** | JSON · SQL · résultat de requête graphe | Authentification, filtres, pagination et limites. |
| **Événement / flux** | JSON · Avro · Protobuf | Schéma d’événement, ordre, doublons, reprise et compatibilité. |
| **Lecture humaine / connaissance** | PDF · HTML · Markdown / OKF | Définitions, sources, date et conditions de réutilisation. |

> Une interface n’est pas un format : une API peut renvoyer du JSON ou un fichier. Le format ne détermine pas les droits ; chaque exposition applique le périmètre autorisé.

# Un contrat rend la donnée réutilisable.

Le producteur annonce ce qu’il fournit et comment le consommer. Le consommateur sait sur quoi il peut s’appuyer.

### Schéma & sens

Identifiants, unités, champs, relations et version.

### Qualité & fraîcheur

Complétude attendue, date de mise à jour et limites connues.

### Accès & responsabilité

Droits, usages autorisés, responsable et contact.

### Évolution & traçabilité

Compatibilité, provenance et annonce des changements.

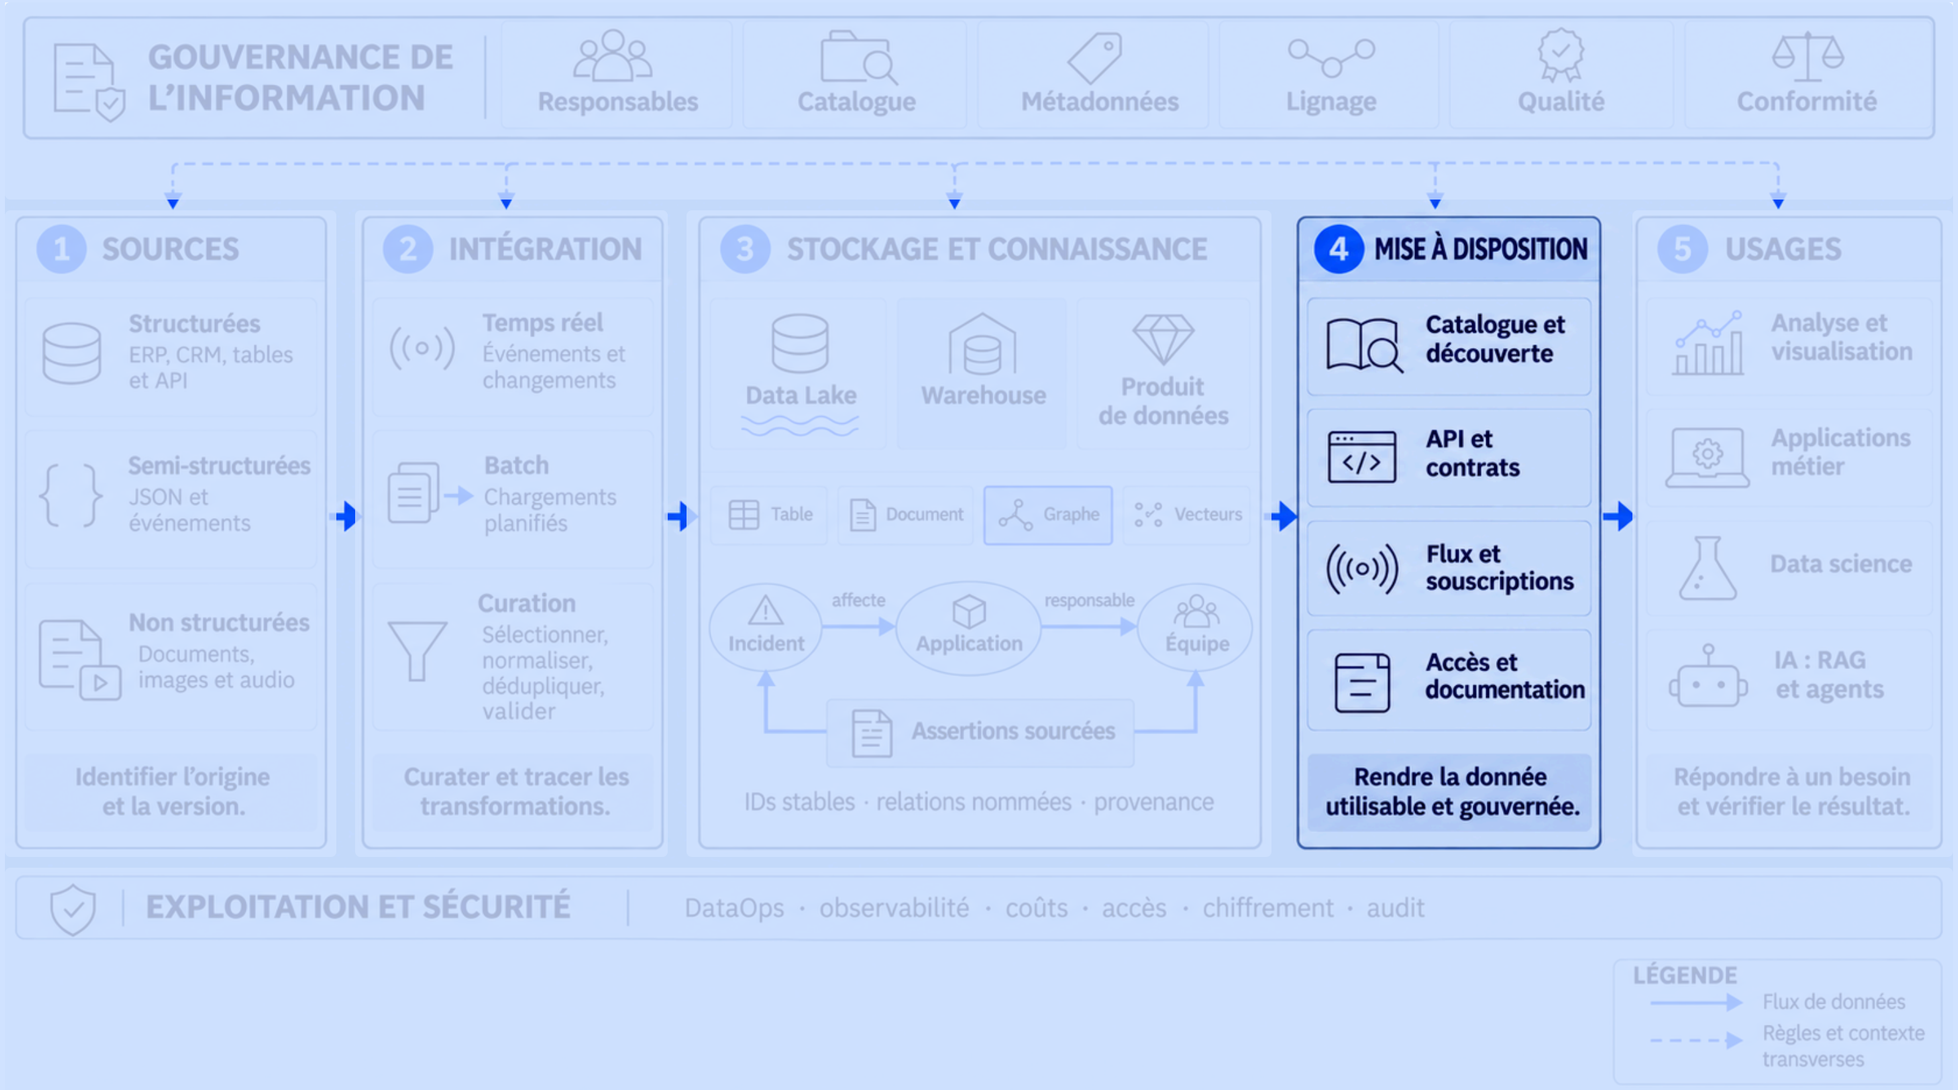
Exemple pédagogique · une API de graphe

```
GET /incidents/INC-204/context
{
  "schema_version": "1",
  "application_id": "app-orion",
  "team_id": "team-payments",
  "source_id": "DOC-01",
  "updated_at": "2026-11-11"
}
```

Une réponse utile conserve ses identifiants stables et l’origine de ses relations.

# La donnée devient accessible avec un contrat.

Catalogue, documentation, API, exports ou flux : la zone qui relie les données qualifiées à leurs consommateurs.



# L’usage détermine la manière de consommer.

ANALYSER

## Visualisation & indicateurs

Un export ou une table alimentent un tableau de bord.

**Vérifier fraîcheur et définitions.**

AGIR

## Application métier

Une API répond à une question ; un événement déclenche un traitement.

**Vérifier droits et contrat.**

RAISONNER AVEC LE CONTEXTE

## IA · RAG · GraphRAG

Un parcours de graphe apporte des relations sourcées au contexte.

**Borner les parcours et évaluer l’apport.**

À VOUS Pour savoir quelle équipe traiterait un incident, quelle interface et quelles preuves demanderiez-vous ?

# De la source à l'usage, chaque étape a sa responsabilité.

Identifier les sources, curater par zones, choisir les représentations, attribuer les responsabilités et exposer selon les droits et les usages, y compris IA.

